# МИНОБРНАУКИ РОССИИ САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ «ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА) Кафедра МО ЭВМ

#### ОТЧЕТ

# по лабораторной работе №5 по дисциплине «Построение и анализ алгоритмов»

Тема: Алгоритм Ахо-Корасик

Студентка гр. 9382	Балаева М.О.
Преподаватель	Фирсов М.А.

Санкт-Петербург

2021

### Цель работы.

Разработать программу, занимающуюся поиском шаблонов в строке, используя алгоритм Ахо-Корасика. Также разработать программу, которая ищет шаблон в строке, который содержит джокера.

#### Задание 1

Разработайте программу, решающую задачу точного поиска набора образцов.

#### Вход:

Первая строка содержит текст  $(T, 1 \le |T| \le 100000)$ .

Вторая - число n ( $1 \le n \le 3000$ ), каждая следующая из n строк содержит шаблон из набора  $P = \{ p_1, ..., p_n \} 1 \le |p_n| \le 75$ 

Все строки содержат символы из алфавита  $\{A, C, G, T, N\}$ 

#### Выход:

Все вхождения образцов из P в T.

Каждое вхождение образца в текст представить в виде двух чисел - i p Где i - позиция в тексте (нумерация начинается с 1), с которой начинается вхождение образца с номером p

(нумерация образцов начинается с 1).

Строки выхода должны быть отсортированы по возрастанию, сначала номера позиции, затем номера шаблона.

#### Sample Input:

NTAG 3 TAGT TAG

Т

#### Sample Output:

2 2 2 3

#### Задание 2

Используя реализацию точного множественного поиска, решите задачу точного поиска для одного образца с *джокером*.

В шаблоне встречается специальный символ, именуемый джокером (wild card), который "совпадает" с любым символом. По заданному содержащему шаблоны образцу PP необходимо найти все вхождения P в текст T.

Например, образец ab??c? с джокером? встречается дважды в тексте xabvccbababcax.

Символ джокер не входит в алфавит, символы которого используются в *Т*. Каждый джокер соответствует одному символу, а не подстроке неопределённой длины. В шаблон входит хотя бы один символ не джокер, т.е. шаблоны вида ??? недопустимы.

Все строки содержат символы из алфавита  $\{A, C, G, T, N\}$ 

#### Вход:

Текст  $(T,1 \le |T| \le 100000)$ 

Шаблон  $(P, 1 \le |P| \le 40)$ 

Символ джокера

#### Выход:

Строки с номерами позиций вхождений шаблона (каждая строка содержит только один номер).

Номера должны выводиться в порядке возрастания.

#### Sample Input:

ACTANCA A\$\$A\$

#### Sample Output:

1

**Вариант 2.** Подсчитать количество вершин в автомате; вывести список найденных образцов, имеющих пересечения с другими найденными образцами в строке поиска.

#### Описание алгоритма.

Описание алгоритма для первого задания.

Изначально на вход подаются: исходный текст, количество шаблонов, шаблоны.

По шаблонам строится бор. Бор — дерево, образованное последовательным добавлением всех образцов посимвольно. Построение начинается с корня, далее каждый символ шаблона добавляется в бор, если он встречается первый раз или нет возможности перехода по ребрам с соответствующими символами, если шаблон заканчивается на текущей вершине, она помечается терминальной.

Далее посимвольно считывается исходный текст, переходя по ребру с символом в следующую вершину, если есть прямой переход, если прямой переход отсутствует, выполняется переход по суффиксной ссылке. Суффиксная ссылка из вершины А — ссылка на вершину, соответствующую длинному (под)образцу максимально В автомате являющемуся несобственным суффиксом (под)образца. Если суффиксная ссылка для вершины не найдена: проверяется является ли данная вершина корнем или его сыном, если является суффиксная ссылка будет равна 0, если не является о выполняется рекурсивный поиск, происходит переход в родителя текущей вершины выполняется переход по его суффиксной ссылке в вершину и из неё осуществляет переход по символу. После перехода в новую вершину инициализируется проверка текущей вершины и её суффиксных ссылок на терминальность, если попадаются терминальные вершины в массив ответов заносится индекс начала вхождения шаблона в исходный текст и его

порядковый номер. Далее считывается очередной символ текста, алгоритм прекратит работу, когда будут обработаны все символы исходного текста. Запоминаем индекс символа последнего найденного шаблона в тексте, если индекс следующего найденного шаблона в тексте отличается от сохраненного индекса на меньше, чем длина следующего шаблона, следовательно эти два шаблона пересеклись в тексте. Количество вершин в автомате соответствует количеству вершин в боре.

Описание алгоритма для второго задания.

Изначально на вход подаются: исходный текст, шаблон с джокером, символ джокера. Далее шаблон разбивается на (под)шаблоны, которые добавляются в бор, как в первом алгоритме. Выделяется массив индексов, длина которого равна длине рассматриваемой строки, инициализированный нулями. Далее происходит посимвольный анализ исходного текста, как в первом алгоритме, однако(!) при попадании в терминальную вершину, что (под)шаблона В (под)шаблона, нахождение исходном тексте инкрементируется значение массива индексов соответствующее началу основного слова относительно найденного (под)шаблона. Получаем, что индексы тех ячеек массива, значение которых будет равно количеству (под)шаблонов в исходном шаблоне, и будут индексами вхождения заданного шаблона в строку. Количество вершин в автомате и пересечение шаблонов находятся аналогично, как в первом алгоритме.

#### Оценка сложности алгоритма.

Оценка сложности по памяти:

Так как автомат хранится, как индексный массив то  $O(M^*P)$ , где M — размер алфавита , P — суммарная длина всех шаблонов.

Оценка сложности по времени:

O(P\*M + T+K), где M — размер алфавита , P — суммарная длина всех шаблонов, T - длина исходного текста, K — общая длина всех вхождений шаблонов в текст.

Тестирование.

# Тестирование первой программы.

Nº	Входные данные	Выходные данные
1	NTAG	2 2
	3	2 3
	TAGT	The number of vertices in the automate: 5
	TAG	List of found patterns that overlap with other found patterns in the
	T	search bar:
		T TAG
2	ALGORITHM	The search has not given any results.
	2	The number of vertices in the automate: 8
	ALCO	List of found patterns that overlap with other found patterns in the
	HMM	search bar, empty
3	ACGTNCTNC	4 1
	TNA	5 2
	3	5 3
	TNC	7 1
	NCTN	8 2
	NC	8 3
		The number of vertices in the automate: 8
		List of found patterns that overlap with other found patterns in the
		search bar:
		TNC NC NCTN
4.	TTCTAG 3 TT	1 1
	C TAG	

3 2
4 3
The number of vertices in the automate: 6
List of found patterns that overlap with other found patterns in the
search bar, empty

# Тестирование второй программы.

No	Входные данные	Выходные данные
1	ACTANCA A\$\$A\$ \$	The index of the occurrence of the pattern in the string:  1 The number of vertices in the automate: 2 A list of found patterns that overlap with other found patterns in the search bar, empty
2	ACACACGTGT ACXXGT X	The index of the occurrence of the pattern in the string:  3 The index of the occurrence of the pattern in the string:  5 The number of vertices in the automate: 5 A list of found patterns that overlap with other found patterns in the search bar ACXXGT
3	ACACACACACCCA A\$A	The index of the occurrence of the pattern in the string:  1 The index of the occurrence of the pattern in the string:  3 The index of the occurrence of the pattern in the string:

		5
		The index of the occurrence of the pattern in the string:
		7
		The number of vertices in the automate: 2
		A list of found patterns that overlap with other found
		patterns in the search bar, emptyThe index of the
		occurrence of the pattern in the string:
		1
		The index of the occurrence of the pattern in the string:
		3
		The index of the occurrence of the pattern in the string:
		5
		The index of the occurrence of the pattern in the string:
		7
		The number of vertices in the automate: 2
		A list of found patterns that overlap with other found
		patterns in the search bar
		A\$A
4	NATNATT	The index of the occurrence of the pattern in the
	NAT%	string:
	0%	1
		The index of the occurrence of the pattern in the
		string:
		4
		The number of vertices in the automate: 4
		A list of found patterns that overlap with other
		found patterns in the search bar
		NAT%
5	CCABXABXXCXAC	The index of the occurrence of the pattern in the
	ABCABABCXACCA	string:
	BXABACCXAB	
	1	

	**AB*AB**C*AC	1
*	The index of the occurrence of the pattern in the	
		string:
		12
		The number of vertices in the automate: 5
		A list of found patterns that overlap with other
		found patterns in the search bar
	**AB*AB**C*AC	
6	CCABXABXXCXAC ABCABABCXACCA BXABACCXAB AB*AB**C*AC	The index of the occurrence of the pattern in the string:  3 The index of the occurrence of the pattern in the
		string:
		The number of vertices in the automate: 5
		A list of found patterns that overlap with other
		found patterns in the search bar  AB*AB**C*AC
7 NATNATT NAT%NAT%	NAT%NAT%NAT	The search has not given any results.  The number of vertices in the automate: 6
		A list of found patterns that overlap with other found patterns in the search bar, empt

## Выводы.

Была разработана программа, занимающаяся поиском шаблонов в строке и находящая все ее вхождения, и был изучен алгоритм Ахо-Корасик. Также была реализована программа, ищущая шаблон в тексте, в котором содержится джокер.

# ПРИЛОЖЕНИЕ А ИСХОДНЫЙ КОД ПРОГРАММЫ ДЛЯ ПЕРВОГО ЗАДАНИЯ.

## Название файла: lab5 1.cpp

```
#include <iostream>
#include <vector>
#include <string>
#include <cstring>
#include <algorithm>

#define N 50

class Bohr {
public:
    int next_vertex[N];
    int pattern_num;
    bool flag;
    int suff_link;
    int auto_move[N];
    int parent;
    char symbol;
```

```
Bohr(int p, char c) : parent(p), symbol(c) {
        memset(next_vertex, 255, sizeof(next_vertex));
        flag = false;
        suff_link = -1;
        memset(auto_move, 255, sizeof(auto_move));
    }
};
std::vector<Bohr> bohr;
std::vector<std::string> pattern;
std::vector<std::pair<int, int>> ans;
std::vector<std::string> cross_Patterns;
int cross count = 0;
int cross_patt = -1;
void init_bohr() {
    std :: cout << "Start building the bohr \n";</pre>
    std::cout<<"The root is denoted as #"<< std::endl;</pre>
    Bohr v(0, -30);
    bohr.push_back(v);
}
void add_pattern_to_bohr(const std::string& s) {
    int num = 0;
    for (int i = 0; i< s.length(); i++) {
        std :: cout << "Consider the symbol : " << i + 1 <<"th: " << s[i] << "\
n";
        char ch = s[i]- 'A';
        if (bohr[num].next_vertex[ch] == -1) {
            Bohr v(num, ch);
            bohr.push_back(v);
            std::cout << "A vertex is added to the selection, to which the cur-
rent symbol of the pattern leads (" << char((v.symbol )+'A') << ") \n";
            bohr[num].next_vertex[ch] = bohr.size() - 1;
        }
        else{
            std::cout << "The vertex (" << s[i] << ") already exists for the
current pattern, you are navigating along it \n";}
        num = bohr[num].next_vertex[ch];
    bohr[num].flag = true;
    std::cout << "The vertex to which the transition is made is terminal, the
construction of the boron branch is finished \n";
    pattern.push back(s);
    bohr[num].pattern_num = pattern.size() - 1;
```

```
}
int get_auto_move(int v, char ch);
int get_suff_link(int v) {
    std::cout << "Calculating suffix and end links for vertex: " << char
(bohr[v].symbol + 'A')<<std::endl;</pre>
    if (bohr[v].suff_link == -1)
        if (v == 0 \mid | bohr[v].parent == 0){
            bohr[v].suff_link = 0;
            std :: cout << "Suffix reference points to root(#) \n";</pre>
        }
    else{
        std :: cout << "Follow the parent's suffix link \n";</pre>
        std::cout<<"Parent is "<< bohr[v].parent << std::endl;</pre>
        bohr[v].suff_link = get_auto_move(get_suff_link(bohr[v].parent),
bohr[v].symbol);
    }
        return bohr[v].suff_link;
}
int get_auto_move(int v, char ch) {
    std::cout << "Looking for a path from the vertex " << char (bohr[v].symbol +</pre>
'A') << " along the edge with the symbol " << char(ch +'A') << ". \n";
    if (bohr[v].auto move[ch] == -1)
        if (bohr[v].next_vertex[ch] != -1){
            std :: cout << "Go to the next node with the corresponding character
\n";
            bohr[v].auto_move[ch] = bohr[v].next_vertex[ch];
        }
        else
            if (v == 0){
                 std :: cout << "The next node with the matching character was</pre>
not found, go to the root node(#) \n";
                bohr[v].auto move[ch] = 0;
            }
            else{
                 std :: cout << "The next node with the matching character was</pre>
not found, let's follow the suffix link \n";
                bohr[v].auto_move(ch] = get_auto_move(get_suff_link(v), ch);
            return bohr[v].auto_move[ch];
}
```

```
void checkout(int v, int i) {
    for (int u = v; u != 0; u = get_suff_link(u)) {
        if (bohr[u].flag){
            std :: cout << "Found pattern in text \n";</pre>
            std::cout << "Position: " << i -
pattern[bohr[u].pattern_num].length() + 1 << ", Number of pattern: " <<</pre>
bohr[u].pattern_num + 1 << "\n";</pre>
            ans.push_back(std::pair<int, int>(i -
pattern[bohr[u].pattern_num].length() + 1, bohr[u].pattern_num + 1));
            if (cross_patt != -1 && i - cross_count <</pre>
pattern[bohr[u].pattern_num].length() + pattern[cross_patt].length()) {
                if (std::find(cross_Patterns.begin(), cross_Patterns.end(), pat-
tern[cross_patt]) == cross_Patterns.end())
                     cross_Patterns.push_back(pattern[cross_patt]);
                if (std::find(cross_Patterns.begin(), cross_Patterns.end(), pat-
tern[bohr[u].pattern_num]) == cross_Patterns.end())
                     cross_Patterns.push_back(pattern[bohr[u].pattern_num]);
            }
            cross_patt = bohr[u].pattern_num;
            cross_count = i - pattern[bohr[u].pattern_num].length();
        }
    }
}
void find_all_pos(const std::string& s) {
    int u = 0;
    for (int i = 0; i<s.length(); i++) {
        std::cout << "Consider the line with the current position: ";</pre>
            for (int j = 0; j < s.length(); j++)
                if (j == i)
                     std::cout << "'" << s[j] << "'";
                else
                     std::cout << s[j];</pre>
        std::cout<<std::endl;</pre>
        u = get_auto_move(u, s[i] - 'A');
        checkout(u, i + 1);
    }
void printer(const std ::string& s){
    find_all_pos(s);
    std::sort(ans.begin(),ans.end());
    if(ans.size()==0){
        std::cout<<"The search has not given any results."<<std::endl;</pre>
```

```
}
    for (int i = 0; i < ans.size(); ++i) {</pre>
        std::cout << ans[i].first << " " << ans[i].second << std::endl;</pre>
    std::cout << "The number of vertices in the automate: " << bohr.size() << "\</pre>
n";
    std::cout << "List of found patterns that overlap with other found patterns</pre>
in the search bar";
    if (cross_Patterns.empty())
        std::cout << ", empty\n";</pre>
    else {
        std::cout << ":\n";
        for (auto& i : cross_Patterns) {
             std::cout << i << " ";
        }
    }
}
int main()
    std::string text;
    std::string pattern;
    int n;
    std::cin >> text >> n ;
    std::cout<<std::endl;</pre>
    init_bohr();
    for (int i = 0; i < n; i++) {
        std::cin >> pattern;
        std::cout<<"Pattern number: "<< i + 1 <<": "<<pattern<<std::endl;</pre>
        add_pattern_to_bohr(pattern);
    printer(text);
    return 0;
}
```

#### приложение Б

## ИСХОДНЫЙ КОД ПРОГРАММЫ ДЛЯ ВТОРОГО ЗАДАНИЯ.

```
Название файла: lab5 2.cpp
#include <iostream>
#include <vector>
#include <sstream>
#include <string>
#include <cstring>
#define N 50
class Bohr {
public:
  int next vertex[N];
  std::vector<int> pattern num;
  bool flag;
  int suff link;
  int auto move[N];
  int parent;
  char symbol;
  Bohr(int p, char c) : parent(p), symbol(c) {
    memset(next vertex, 255, sizeof(next vertex));
    flag = false;
     suff link = -1;
    memset(auto move, 255, sizeof(auto move));
    pattern num.resize(0);
  }
};
std::vector<Bohr> bohr;
```

```
int cross count = -1;
bool is cross = false;
void init bohr() {
  std :: cout << "Start building the bohr \n";
  std::cout<<"The root is denoted as #"<< std::endl;
  Bohr v(0,-30);
  bohr.push back(v);
}
void add pattern to bohr(const std::string& s, int& count) {
  int num = 0;
  for (int i = 0; i < s.length(); i++) {
     std :: cout << "Consider the symbol : " << i + 1 <<"th: " << s[i] << "\n";
     char ch = s[i] - A';
     if (bohr[num].next vertex[ch] == -1) {
       Bohr v(num, ch);
       bohr.push back(v);
       std::cout << "A vertex is added to the selection, to which the current sym-
bol of the pattern leads (" << char((v.symbol )+'A') << ") n";
       bohr[num].next vertex[ch] = bohr.size() - 1;
     }
     else{
       std::cout << "The vertex (" << s[i] << ") already exists for the current pat-
tern, you are navigating along it \n";}
     num = bohr[num].next vertex[ch];
  }
```

```
bohr[num].flag = true;
  std::cout << "The vertex to which the transition is made is terminal, the con-
struction of the boron branch is finished \n";
  bohr[num].pattern num.push back(++count);
std::cout<<"-----
 -----"<<std::endl;
std::cout<<"-----
-----"<<std::endl:
int get auto move(int v, char ch);
int get suff link(int v) {
  std::cout << "Calculating suffix and end links for vertex: " << char
(bohr[v].symbol + 'A') << std::endl;
  if (bohr[v].suff link == -1)
    if (v == 0 \parallel bohr[v].parent == 0){
      std :: cout << "Suffix reference points to root(#) \n";
      bohr[v].suff link = 0;
    }
  else {
    std :: cout << "Follow the parent's suffix link \n";
    std::cout<<"Parent is "<< bohr[bohr[v].parent].symbol << std::endl;
    bohr[v].suff link = get auto move(get suff link(bohr[v].parent),
bohr[v].symbol);
  }
    return bohr[v].suff link;
```

```
}
int get auto move(int v, char ch) {
  std::cout << "Looking for a path from the vertex " << char (bohr[v].symbol +
'A') << " along the edge with the symbol " << char(ch +'A') << ". \n";
  if (bohr[v].auto move[ch] == -1)
     if (bohr[v].next vertex[ch]!=-1){
       std:: cout << "Go to the next node with the corresponding character \n";
       bohr[v].auto move[ch] = bohr[v].next vertex[ch];
    }
     else
       if(v == 0)
         std:: cout << "The next node with the matching character was not found,
go to the root node(\#) \n";
         bohr[v].auto move[ch] = 0;
       }
       else{
          std:: cout << "The next node with the matching character was not found,
let's follow the suffix link \n";
         bohr[v].auto move[ch] = get auto move(get suff link(v), ch);
       }
       return bohr[v].auto move[ch];
}
void checkout(int u, int i, const std::string& s, std::vector<int>& count,
std::vector<int>&pattern offset mass, int pat len, std::vector<std::string>&
pat mass, std::string pattern){
  for (int tmp = u; tmp != 0; tmp = get suff link(tmp)) {
     if (bohr[tmp].flag) {
```

```
for (int j = 0; j < bohr[tmp].pattern num.size(); j++) {
          // если находится в промежутке от 0 до размера текста - размер
паттерна
          if ((i + 1 - pattern offset mass[bohr[tmp].pattern num[i] - 1] -
pat mass[bohr[tmp].pattern num[i] - 1].size() \geq 0) && (i + 1 -
pattern offset mass[bohr[tmp].pattern num[i] - 1] -
pat mass[bohr[tmp].pattern num[j] - 1].size() <= s.size() - pat len)) {
            std::cout<<"";
            count[i + 1 - pattern offset mass[bohr[tmp].pattern num[i] - 1] -
pat mass[bohr[tmp].pattern num[j] - 1].size()]++;
            std::cout << "Terminal vertex," << "subpattern = " << pat mass[bohr
[tmp].pattern num[j] - 1] << "\n";
            if (count[i + 1 - pattern offset mass[bohr[tmp].pattern num[j] - 1] -
pat mass[bohr[tmp].pattern num[i] - 1].size()] == pattern offset mass.size()) {
               std::cout << "Pattern occurrence found" << '\n';
               std::cout<<"Is there an overlap with other found patterns in the
search bar."<<std::endl;
               if (cross count != -1 && i - cross count < pattern.length() + pat-
tern.length()) {
                 std::cout<<"The intersection with other found patterns in the
search bar is."<<std::endl;
                 is cross = true;
               } else{
                 std::cout<<"There is no intersection with other found patterns in
the search bar"<<std::endl;
               }
               cross count = i - pattern.length() + 1;
            }
          }
```

```
}
void find all pos(const std::string& s, std::vector<int>& count,
std::vector<int>&pattern offset mass, int pat len, std::vector<std::string>&
pat mass, std::string pattern) {
  int u = 0;
  for (size t i = 0; i < s.size(); i++) {
     std::cout << "Consider the line with the current position: ";
     for (int j = 0; j < s.length(); j++)
       if (i == i)
          std::cout << """ << s[i] << """;
       else
          std::cout << s[j];
      std::cout<<std::endl;
     u = get auto move(u, s[i] - 'A');
     checkout(u, i, s, count, pattern offset mass, pat len, pat mass, pattern);
std::cout<<"-----
-----"<<std::endl:
}
void split pattern(std::string pattern, char joker, std::vector<std::string>& pat mas,
std::vector<int>& pattern offset mas){
  std::cout << "Break the original pattern by jokers, into (sub)patterns. \n";
```

```
std::string buf = "";
  for (int i = 0; i < pattern.size(); i++) {
     if (pattern[i] == joker){
       if (buf.size() > 0) {
          pat mas.push back(buf);
          std::cout << "Found a new subpattern: " << buf << "\n";
          pattern offset mas.push back(i - buf.size());
          buf = "";
        }
     }
     else {
       buf.push back(pattern[i]);
       if (i == pattern.size() - 1) {
          std::cout << "Found a new subpattern:" << buf << "\n";
          pat mas.push back(buf);
          pattern offset mas.push back(i - buf.size() + 1);
          std::cout << "Starting index in the original pattern:" << i - buf.size () + 1
<< "\n";
     }
}
void out(std::vector<int>& count, int pat counter, std::string& s, std::string pat-
tern) {
  int k = 0;
  for (int i = 0; i < \text{count.size}(); i++) {
```

```
if (count[i] == pat counter) {
       std::cout<<"The index of the occurrence of the pattern in the
string:"<<std::endl;
       std::cout << i + 1 << "\n";
     } else k++;
  }
  if(k==count.size()){
     std::cout<<"The search has not given any results."<<std::endl;
  std::cout<<"The number of vertices in the automate: " <<bohr.size()<<std::endl;
  std::cout<<"A list of found patterns that overlap with other found patterns in the
search bar";
  if (!is cross)
     std::cout<<", empty"<< std::endl;
  else{
     std::cout<<"\n";
     std::cout<<pattern<<std::endl;
  }
}
int main()
{
  init bohr();
  std::string text;
  std::string pattern;
  std::vector<int> pattern offset mass;
  char joker;
  std::cin >> text >> pattern >> joker;
```

```
std::vector<int> count(text.size(), 0);
std::vector<std::string> patt_mass;
split_pattern(pattern, joker, patt_mass, pattern_offset_mass);
int k = 0;
for (auto pat : patt_mass) {
    add_pattern_to_bohr(pat, k);
}
find_all_pos(text, count, pattern_offset_mass, pattern.size(), patt_mass, pattern);
std::cout<<std::endl;
out(count, patt_mass.size(), text, pattern);
return 0;
}</pre>
```